# Caracterización de personajes y generación de libretos para cortometrajes usando LLMs

William Salamanca, Ingenieria de Sistemas y Computación, UPTC Yasser Cristancho, Ingenieria de Sistemas y Computación, UPTC

#### **Index Terms**

LLM, AI, PLN, Fine Tunning, Transformer

#### I. Introducción

En la industria cinematográfica también se ha evidenciado el crecimiento de la revolución digital, aportando avances tecnológicos en la generación de productos visuales. Sin embargo, uno de los aspectos más fundamentales como la creación de personajes y la escritura de libretos sigue siendo muy manual.

Dentro del entorno cinematográfico, los cortometrajes permiten brindar una visualización de entretenimiento en corto tiempo a los espectadores para dejar un mensaje o transmitir emociones a partir de una historia. Para la creación de un cortometraje, la caracterización y la creación de un libreto son fundamentales para construir historias memorables y cautivadoras. Los personajes bien definidos con sus características únicas son la base de cualquier narración. Por otro lado, la creación de libretos requiere tener un amplio dominio en escritura y el arte de generar historias de manera atractiva, lo que puede llevar mucho tiempo.

Los Modelos de Lenguaje Largos o Extensos, de su traducción en sus siglas en inglés LLM (Language Large Models), han permitido evidenciar la capacidad potencial de generar texto o contenido para diferentes tareas [Hadi et al., 2023]. Contemplando lo anterior, en este proyecto se propone desarrollar un sistema que pueda analizar la narrativa del fragmento de un libro con el fin de explorar la aplicación de LLM para la identificación de personajes con sus características detalladas y la generación de libretos dependiendo del contexto que se ingrese en términos de ubicación, época, entre otros.

#### II. PLANTEAMIENTO DEL PROBLEMA

En la etapa de preproducción de una obra, guion o cortometraje, la creación de personajes detallados y bien definidos es fundamental para construir una historia cautivadora y convincente. Sin embargo, este proceso suele ser laborioso y requerir una amplia investigación y esfuerzo creativo por parte de los guionistas y directores. Mediante la implementación de un modelo LLM especializado en caracterización de personajes, se busca automatizar y agilizar esta tarea, permitiendo la generación de descripciones detalladas y coherentes de personajes a partir de un fragmento de una narrativa corta.

Por otra parte, la escritura del libreto es una etapa crucial en la producción cinematográfica de cortometrajes. Requiere habilidades narrativas, conocimiento del formato de guiones y una gran inversión de tiempo. Al utilizar un modelo LLM entrenado específicamente para la generación de libretos, se pretende agilizar este proceso, brindando a los guionistas y directores una herramienta poderosa que les permita obtener borradores iniciales de libretos a partir de una idea.

El objetivo principal de este proyecto es desarrollar una solución innovadora que aproveche la potencia de los modelos de lenguaje grandes (LLM) para facilitar y agilizar dos tareas clave en la producción de cortometrajes: la caracterización de personajes y la generación de libretos. Estos modelos serán entrenados con conjuntos de datos específicos y relevantes para cada tarea, utilizando técnicas de aprendizaje supervisado, buscando ahorrar tiempo y recursos.

### III. MARCO CONCEPTUAL

#### III-A. Procesamiento de Leguaje Natural

El PLN es un campo de la informática que se ocupa de la interacción entre las computadoras y el lenguaje humano. Se centra en el desarrollo de métodos para que las computadoras puedan comprender, procesar y generar lenguaje natural.

## III-B. Inteligencia Artificial

Es una rama de la informática que se ocupa del desarrollo de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la percepción, el razonamiento y la resolución de problemas.

# III-C. LLM

Los Modelos de Lenguaje Grandes (LLM, por sus siglas en inglés) son modelos de lenguaje entrenados en grandes cantidades de datos de texto, con millones o miles de millones de parámetros, lo que les permite capturar y representar relaciones complejas y sutilezas en el lenguaje natural

1

## III-D. Transformer

El Transformer es una arquitectura de redes neuronales que se ha convertido en el estándar de facto para tareas de procesamiento de lenguaje natural, como la traducción automática, el resumen de texto y la generación de texto

# III-E. Fine Tunning

El Fine-Tuning, o ajuste fino, es una técnica utilizada en el aprendizaje de transferencia, donde un modelo preentrenado se ajusta aún más en un conjunto de datos específico de la tarea objetivo, lo que permite adaptar el modelo a un dominio o tarea particular

#### IV. METODOLOGÍA

## IV-A. Explorar LLMs

Se necesita tener una vista general de la variedad de LLMs que se encuentran actualmente implementados y desplegados.

# IV-B. Explorar documentación de los LLMs

Identificar aspectos relacionados a los requerimientos básicos y/o necesarios de los LLMs para poder hacer finetune de estos. Requerimientos de software y hardware, así como posibles comparativas que indiquen su desempeño en tareas de NPL, específicamente en las de identificar, caracterizar y clasificar personajes de libros. Además de la generación de libretos para cortometrajes a partir de personajes identificados, caracterizados y clasificados, y de un contexto histórico en el que se desarrolla el libreto.

# IV-C. Explorar fuentes de datos

Para el proceso de finetune de un LLM seleccionado se necesita tener varias fuentes de datos que en un principio nos provean de una descripción de las características de los personajes que se encuentran en este. Adicionalmente a lo anterior, se necesitan datos sobre contextos historicos con el fin de tener un contexto en el que se desarrolla el libreto para el cortometraje.

## IV-D. Comparativa inicial entre LLMs seleccionados

- Capacidad de los modelos para realizar las tareas de identificación, caracterización y clasificación de personajes, además de la generación de libretos con base a lo anterior y un contexto historio dado.
- Tamaños y complejidades asociados a los modelos.
- Disponibilidad y acceso.
- Requerimientos de hardware.

## IV-E. Comparativa mediante ejercicios entre LLMs seleccionados

Partiendo de las mismas entradas y con las mismas condiciones de hardware, identificar el que tenga mejor rendimiento en términos de tiempo pero, teniendo en cuenta la calidad de la salida.

# IV-F. Herramientas

- Lenguaje de programación: Python.
- Bibliotecas: Hugging Face Transformers.
- Modelos Preentrenados: T5.
- Entorno: GoogleColab.
- Control de Versiones: Git y GitHub.
- Pypdf: Librería para extraer texto de PDFs

# V. EXPLORACIÓN DE HERRAMIENTAS SELECCIONADAS

```
from pypdf import PdfReader
...
# creating a pdf reader object
reader = PdfReader('example.pdf')
...
# printing number of pages in pdf file
print("Numero de paginas",len(reader.pages))
...
# getting a specific page from the pdf file
page = reader.pages[11]
...
# extracting text from page
text = page.extract_text()
print(text)
```

Figura 1. Uso de la librería PyPDF

```
bython > python3 read_pdf.py
Numero de paginas 96
12Hace 6 años, estaba volando
sobre el desierto del Sahara
y se estropeó el motor de mi avión.
Estaba completamente solo.
No tenía mecánico ni pasajeros.
Tenía que reparar el avión yo mismo
y solo tenía agua para 8 días.
Era una cuestión de vida o muerte.
La primera noche me quedé dormido
sobre la arena a miles de kilómetros
de cualquier lugar habitado.
Me sentía como un náufrago en medio del océano.
Os podéis imaginar mi sorpresa
cuando me despertó una extraña vocecita
que me dijo:
vocecita - Por favor, ¡dibújame un cordero!
Di un respingo y me froté los ojos.
Vi una personita extraordinaria
que me miraba fijamente.
```

Figura 2. Uso de la librería PyPDF

Modelo	Capacidad de Tokenización (Límite de Contexto)	Tipo	Número de Parámetros
GPT-1	512 tokens	Pago	117M
GPT-2	1024 tokens	Código libre	1.5B
GPT-3	2048 tokens	Pago	175B
GPT-4	Hasta 8192 tokens o más, dependiendo de la configuración	Pago	175B+
Megatron-LM	2048 tokens	Código libre	8.3B
PaLM	2048 tokens	Pago	540B
LaMDA	Hasta 2048 tokens	Pago	137B
GPT-Neo	2048 tokens	Código libre	1.3B y 2.7B
GPT-J	2048 tokens	Código libre	6B
BERT	512 tokens	Código libre	110M
RoBERTa	512 tokens	Código libre	355M
T5	512 tokens	Código libre	11B
DistilBERT	512 tokens	Código libre	66M
Tabla I			

CAPACIDAD DE TOKENIZACIÓN, TIPO Y NÚMERO DE PARÁMETROS DE LLMS IDENTIFICADOS

## VI. LLMs seleccionados

# VI-A. GPT-Neo

"Hace 6 años, estaba volando sobre el desierto del Sahara y se estropeó el motor de mi avión. Estaba completamente solo"3.

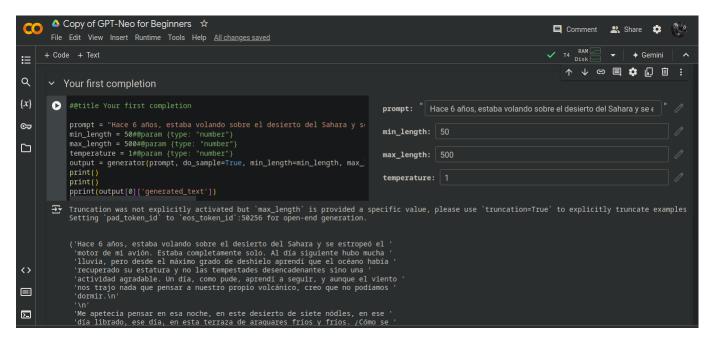


Figura 3. Ejemplo GPT-Neo

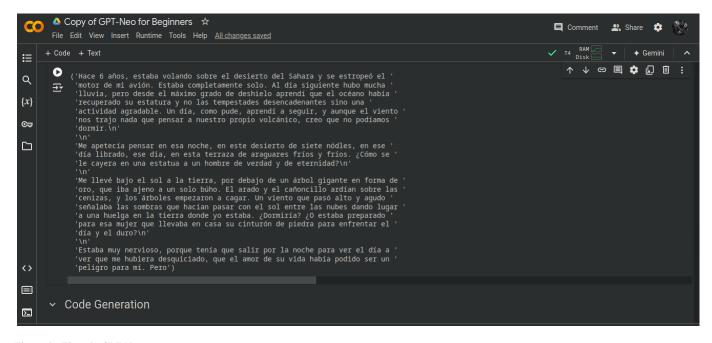


Figura 4. Ejemplo GPT-Neo

#### *VI-B*. *T5*

```
model_name = "t5-base"
tokenizer = T5Tokenizer.from_pretrained(model_name)
model = T5ForconditionalGeneration.from_pretrained(model_name)

character_description = """

Once upon a time, in a small village, lived a miller who had three sons. When he passed away, he left each son an inheritance. The eldest received the mill, the second the donkey, and Distraught, the youngest son lamented his fate, thinking that while his brothers could earn a livelhood, he would surely starve. The cat, overhearing him, said, "Do not despair, my n Puss filled the sack with carrots and laid it open in a rabbit clearing, Soon enough, a rabbit hopped in, and Puss quickly closed the sack, bringing the rabbit to the king as a gift of the king was pleased and thanked the Marquis, without knowing who he really was. Puss repeated this trick several times, always bringing game to the king, saying it was from his master on eday, Puss learned that the king and his beautiful daughter would be riding by the river, Quickly, he told his master to bathe in the river and then hid his clothes. As the king's The king recognized the cat who had brought him so many gifts and ordered his guards to help. Puss told the king that robbers had stolen his master's clothes. The king promptly offered be king river, Quickly, he told his master to bathe in the river and then hid his clothes. As the king's The king recognized the cat who had brought him so many gifts and ordered his guards to help. Puss told the king that robbers had stolen his master's clothes. The king promptly offered prompts of carbas, and the king arriver, Puss another of which we have a son been a stolen his master's clothes. The king promptly offered being the king river and the hid his clothes. As the king's The king promptly offered puss and cate owned by a cruel ogre. Puss challenged the ogre to transformative power of wit and courage.

The youngest son, now the Manquis of Carabas, married the princess, and they all lived happily ever after, all thanks to the clever cat with boots.

Th
```

Figura 5. Ejemplo caracterizacion de personajes T5.

```
[] # Ejemplo de diálogo de un libro
book_dialogue = """

"¿Estás listo para la aventura?", preguntó Ana con una sonrisa traviesa.

"Por supuesto", respondió Juan emocionado. "Siempre estoy listo para explorar lo
Ana se rio. "Entonces, ¿qué estamos esperando? ¡Vamos!"

"""

prompt_dialogue = "Convierte el siguiente diálogo de un libro en un libreto corto para una obra de teatro: "
input_text_dialogue = prompt + book_dialogue
encoded_input_d = tokenizer(input_text_dialogue, return_tensors="pt")
generated_output_d = model.generate(encoded_input_d["input_ids"], max_length=500)
decoded_output_d = tokenizer.decode(generated_output_d[0], skip_special_tokens=True)
print(decoded_output_d)

Ana emocionado en la descripción textual proporcionada. "Estás listo para la aventura?", preguntó Juan emocionado. "Vamos!", afirmó Juan. "Qué estamos esperando? Vamos!"
```

Figura 6. Ejemplo generación libreto T5.

#### VI-C. GPT-4

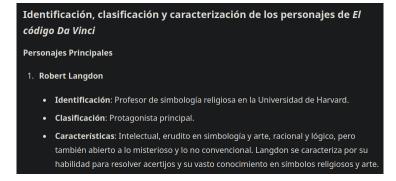


Figura 7. Identificación, caracterización y clasificación de personajes: El código Da Vinci

#### 2. Sophie Neveu

- Identificación: Criptóloga de la policía francesa.
- Clasificación: Protagonista femenina
- Características: Inteligente, ingeniosa y valiente. Tiene una conexión personal con el misterio central de la historia, ya que es la nieta de Jacques Saunière. Su habilidad en criptología y su conocimiento de la obra de su abuelo son cruciales para el desarrollo de la trama.

#### 3. Jacques Saunière

- Identificación: Curador del Museo del Louvre.
- Clasificación: Personaje clave cuyo asesinato desencadena la trama.
- Características: Misterioso y enigmático, dejó una serie de pistas criptográficas antes de morir. Saunière es un erudito en arte y símbolos, y su relación con el Priorato de Sion es central en la historia.

Figura 8. Identificación, caracterización y clasificación de personajes: El código Da Vinci

#### 4. Silas

- Identificación: Monje albino y asesino al servicio de "El Maestro".
- Clasificación: Antagonista.
- Características: Devoto y fanático, Silas está profundamente influenciado por su fe y su necesidad de redención. Su carácter está marcado por su pasado traumático y su ferviente creencia en su misión divina.

#### 5. Leigh Teabing

- Identificación: Historiador y ex académico británico.
- Clasificación: Antagonista oculto.
- Características: Erudito en temas del Santo Grial, Teabing es carismático y
  persuasivo. Sin embargo, su ambición y deseo de revelar la verdad sobre el Santo
  Grial lo llevan a traicionar a Langdon y Neveu. Es astuto y manipula a otros para
  alcanzar sus objetivos.

Figura 9. Identificación, caracterización y clasificación de personajes: El código Da Vinci

# Personajes Secundarios

#### 1. Bezu Fache

- Identificación: Capitán de la Policía Judicial francesa.
- Clasificación: Antagonista secundario.
- Características: Determinado y autoritario, Fache sospecha inicialmente de Langdon en relación con el asesinato de Saunière. Es persistente y está decidido a resolver el caso, a menudo utilizando métodos directos y agresivos.

# 2. Manuel Aringarosa

- Identificación: Obispo y líder del Opus Dei.
- Clasificación: Antagonista secundario.
- Características: Devoto y ambicioso, Aringarosa está profundamente involucrado en las maquinaciones detrás del conflicto central. Su lealtad al Opus Dei y su deseo de proteger la Iglesia lo llevan a tomar decisiones cuestionables.

Figura 10. Identificación, caracterización y clasificación de personajes: El código Da Vinci

#### VII. FUENTES DE DATOS SELECCIONADOS

Libros de cuentos y relatos cortos: Los libros de cuentos y relatos cortos son una fuente viable de fragmentos narrativos
concisos, que podrían servir como base para desarrollar cortometrajes. Algunos ejemplos son los cuentos de Edgar Allan
Poe, Anton Chéjov, Jorge Luis Borges, entre otros.

- Antologías de historias cortas: Las antologías recopilan historias cortas de diversos autores y géneros, lo que te brindaría una amplia variedad de estilos y temáticas para trabajar.
- Novelas cortas: Las novelas cortas, también conocidas como "novellas", son obras narrativas más extensas que un cuento, pero más breves que una novela completa. Podrías extraer fragmentos o capítulos completos de estas obras.
- Obras de teatro de un acto: Las obras de teatro de un acto, al ser más cortas y condensadas, son una excelente fuente de diálogos y tramas compactas que podrían adaptarse fácilmente a cortometrajes.
- Repositorios de guiones y libretos: Existen repositorios en línea que compilan guiones y libretos de películas, series de televisión y obras de teatro. Aunque no son fragmentos literarios, podrían ser útiles para aprender sobre la estructura y el formato de los libretos.
- Sitios web y plataformas de escritura creativa: Algunas plataformas en línea, como Wattpad, Inkitt o WritingPrompts, albergan historias cortas, relatos y escritos creativos de autores emergentes. Estos podrían ser una fuente interesante de material.

## VIII. HALLAZGOS

Existen diferentes opciones de LLMs, particularmente de código y uso libre. Pero es evidente que las herramientas que mejor rendimiento y calidad de salida tienen son las que tienen costo por su uso, específicamente GPT-4 realiza exitosamente la tarea de identificar, caracterizar y clasificar personajes. Dentro de la capa gratuita de GPT-4 podemos obtener datos de la identificación, caracterización y clasificación de personajes para el LLM seleccionado.

#### IX. CONCLUSIÓN

Partiendo de los aspectos generales de los LLMs identificados, descartamos los que tuvieran asociado un costo para su uso. Además se identificó y seleccionó el LLMs que provee una mayor capacidad de tokenización, siendo en este caso GPT-Neo.

# X. BIBLIOGRAFÍA

#### REFERENCIAS

[Hadi et al., 2023] Hadi, M. U., Al-Tashi, Q., Qureshi, R., Shah, A., Muneer, A., Irfan, M., Zafar, A., Shaikh, M., Akhtar, N., Wu, J., and Mirjalili, S. (2023). Large language models: A comprehensive survey of its applications, challenges, limitations, and future prospects.